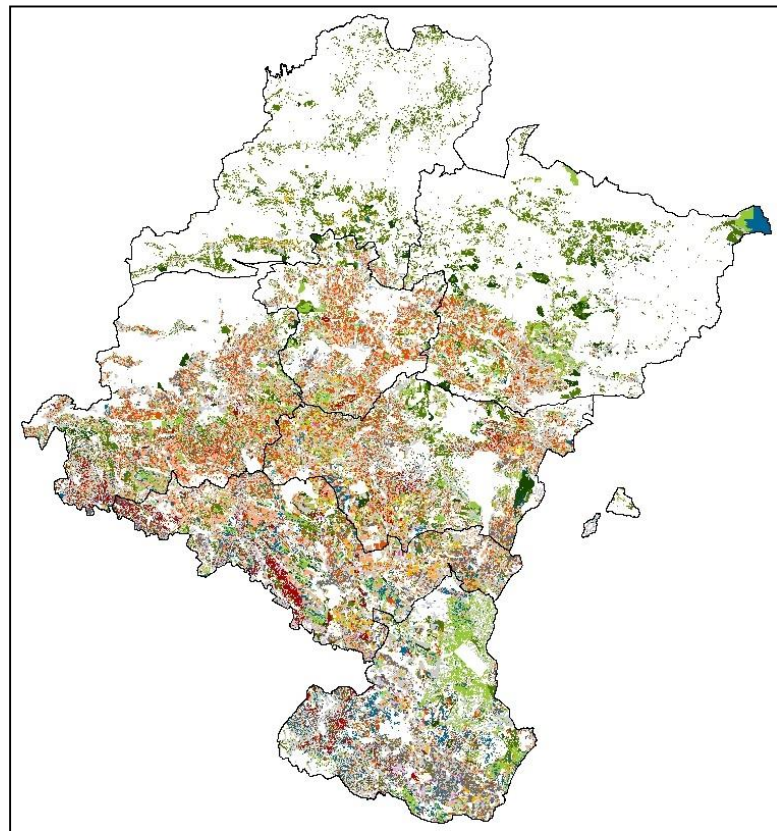


Clasificación de cultivos y cubiertas forestales de Navarra con Sentinel-1, Sentinel-2 y LiDAR

Gabriel Bonifaz*, Itxaso Aranguren, María González-Audícana, Jesús Álvarez-Mozos

*autor que presenta: gabriel.bonifaz@unavarra.es

Universidad Pública de Navarra,
IS-FOOD (Instituto de innovación y sostenibilidad en la cadena
alimentaria)



- La información sobre usos y cubiertas del suelo es una información geográfica de referencia, necesaria para una gestión adecuada del territorio.
- En concreto el mapeo de cultivos permite realizar anualmente la estadística agraria, previsiones de cosecha, asegurar la seguridad alimentaria y es también una herramienta para la gestión de subsidios y ayudas (e.g., PAC).
- En lo que respecta a los bosques, la cartografía de especies forestales resulta esencial para la realización de inventarios forestales, estudios medioambientales y de biodiversidad o el seguimiento de los gases de efecto invernadero y el cambio climático.

- La obtención de esta información mediante trabajo de campo es impensable a día de hoy, por eso es necesario desarrollar herramientas que permitan la obtención de estas capas de información de forma precisa y a la vez rápida y económica.
- La teledetección es la fuente de datos idónea para este tipo de aplicaciones.
- La clasificación de imágenes (supervisada o no supervisada) es una técnica de análisis consolidada para producir este tipo de información temática.



Imagen satelital

clasificación



Mapa temático

-El programa europeo Copernicus, y en concreto las misiones Sentinel, proporcionan datos potencialmente útiles para este tipo de aplicaciones, con una resolución espacial y temporal idónea para la mayoría de casos.




(Fuente: ESA)

Sentinel-1: radar en banda C

Interés: La retrodispersión en polarizaciones VV y VH depende de características geométricas (arquitectura del dosel, forma y tamaño de hojas, tallos, etc.) y dieléctricas (humedad) de las cubiertas.

Sentinel-2: sensor óptico multispectral

Interés: Mide la reflectancia en diferentes bandas espectrales, que depende de características de la vegetación como sus pigmentos, estructura celular, contenido de humedad, etc.



(Fuente: ESA)

-Tradicionalmente la clasificación de cultivos y bosques se ha abordado principalmente a partir de imágenes adquiridas por sensores ópticos.

-En las últimas décadas el uso de imágenes adquiridas por sensores radar para estas aplicaciones está aumentando.

-Debido a la complementariedad de la información que ofrecen, resulta idóneo combinar ambos tipos de datos.



Cuenca de Pamplona, Sentinel-2



Cuenca de Pamplona, Sentinel-1

-El objetivo general de esta ponencia es presentar dos casos de estudio en los que se han implementado distintas alternativas metodológicas que han permitido obtener clasificaciones precisas tanto en bosques como en zonas cultivadas de Navarra.

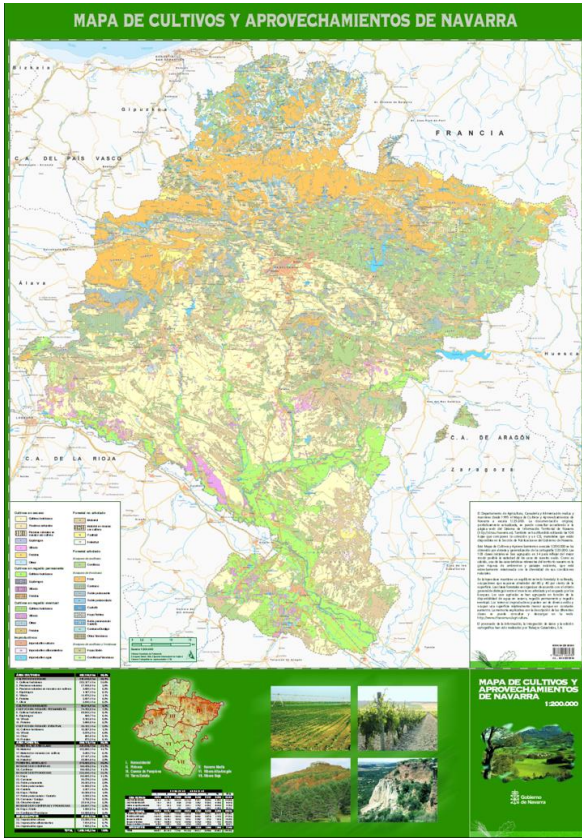
-Como objetivos específicos se pueden mencionar los siguientes:

1. Utilizar como información de partida datos libres (tanto como sea posible)
2. Utilizar herramientas abiertas (tanto como sea posible)
3. Evaluar la complementariedad de las distintas fuentes de información utilizada
4. Adaptar las metodologías a cada caso atendiendo a sus particularidades y realizar una comparativa entre ambos casos de estudio

-El Gobierno de Navarra realiza y mantiene desde 1995 el Mapa de Cultivos y Aprovechamientos de Navarra a escala 1/25.000.

-La leyenda de especies forestales se agrupa en 3 niveles:

Nivel 1 (3 clases)	Nivel 2 (11 clases)	Nivel 3 (23 clases)
Frondosas	Haya, Quercus, Frondosas nobles, Otras frondosas	Carrasca, Chopo y álamo, Encina, Haya, Quejigo, R. Americano, R. Pedunculado, R. pubescente, Nobles, Minoritarias y mezcla
Coníferas	P. Carrasco, P. Laricio, P. Silvestre, Otras coníferas	Abeto, Alerce, P. Carrasco, P. Insignis, P. Laricio, P. Silvestre, Minoritarias y Mezcla
Mixtas	P. silvestre-Hayedo, P.silvestre-Robledal, Otras mezclas mixtas	Hayedo-Abetal, P. silvestre-Hayedo, P.silvestre-Robledal, Otras mezclas mixtas



-El Mapa de Cultivos y Aprovechamientos se obtiene por fotointerpretación y trabajo de campo y se va actualizando, aunque sin una periodicidad fija (1, 2, 7 años).

-De cara a este trabajo se contemplan dos posibles alternativas de actualización:

1-Anual: basada en coberturas anuales Sentinel-1 y Sentinel-2

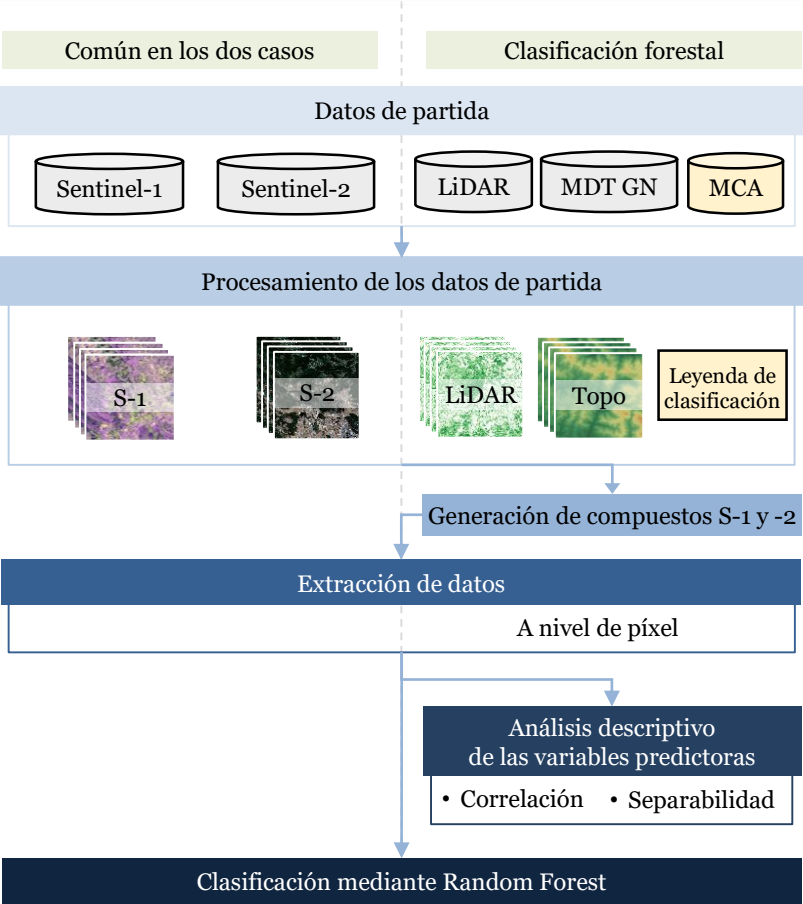
2-Quinquenal-Decenal: basada en Sentinel-1, Sentinel-2 + LiDAR

-Para este trabajo se procesa la 2ª cobertura del PNOA-LiDAR, adquirida sobre Navarra en 2017 con una densidad de 14 p/m².

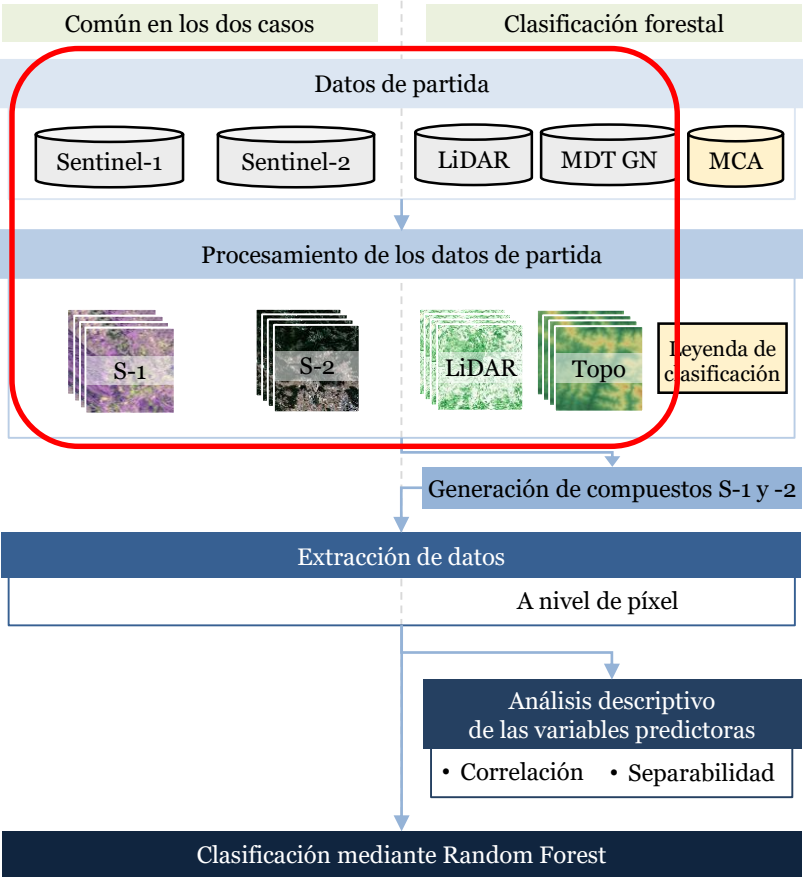
-Se plantea una clasificación por píxel, tomando un píxel de 10x10m.



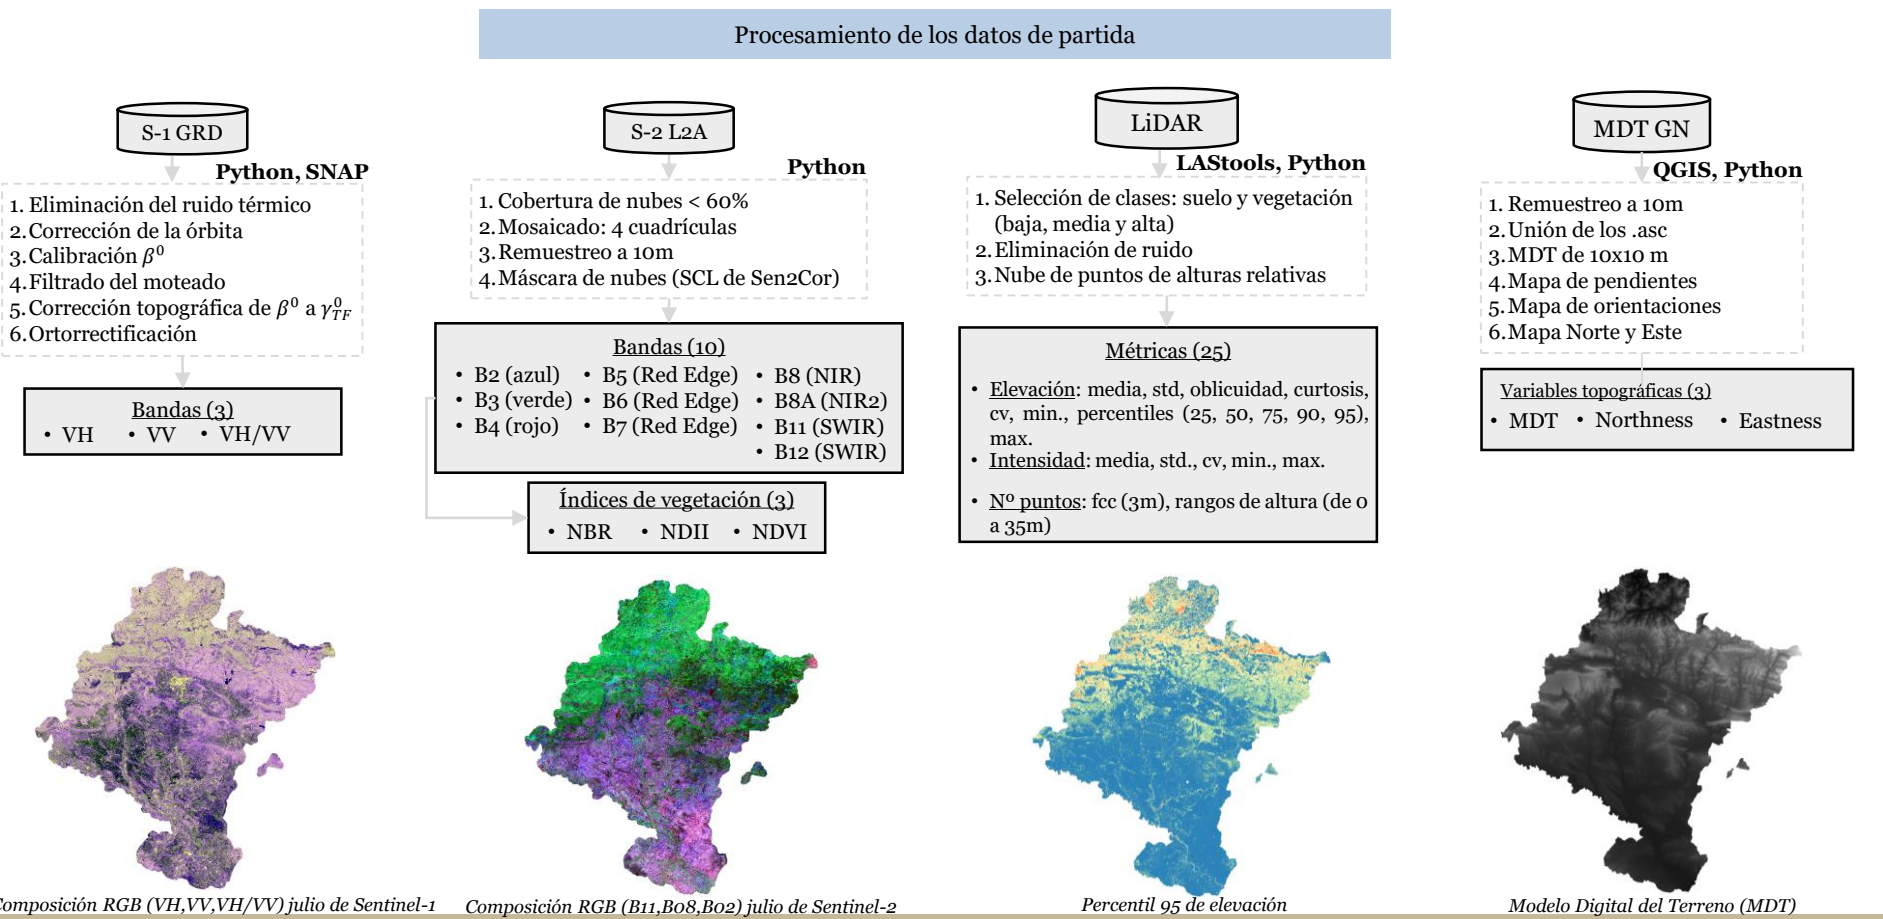
Caso de estudio 1: Clasificación de especies forestales. Metodología



Caso de estudio 1: Clasificación de especies forestales. Metodología

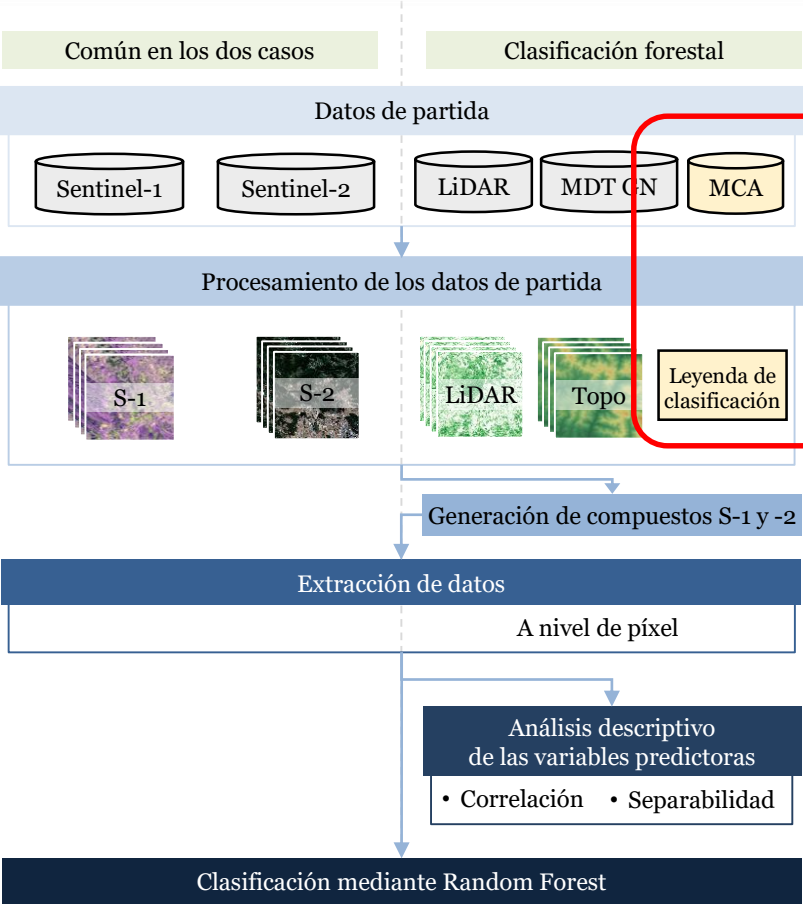


Caso de estudio 1: Clasificación de especies forestales. Metodología



Composición RGB (VH,VV,VH/VV) julio de Sentinel-1 Composición RGB (B11,B08,B02) julio de Sentinel-2 Percentil 95 de elevación Modelo Digital del Terreno (MDT)

Caso de estudio 1: Clasificación de especies forestales. Metodología



Procesamiento de los datos de partida

Mapa de Cultivos
y Aprovechamientos (MCA)

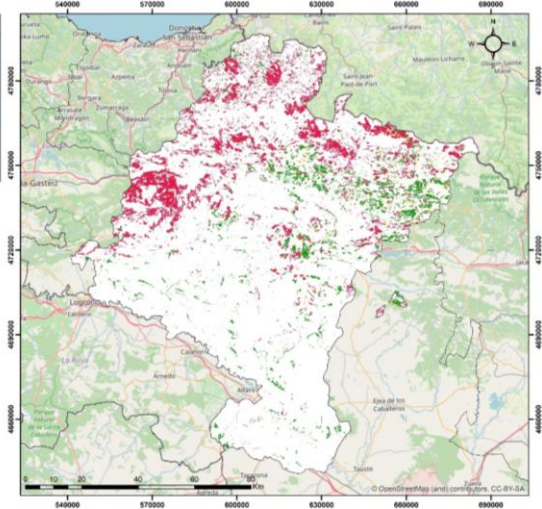
QGIS

1. Selección de masas forestales: coníferas, frondosas y mixtas
2. Eliminación de las masas susceptibles de cortas
3. Enmascarado de: masas de agua y ríos, líneas eléctricas, zonas urbanas y redes de comunicación
4. Aplicación de un buffer de 5m para eliminar el efecto borde
5. Selección de masas > 1ha



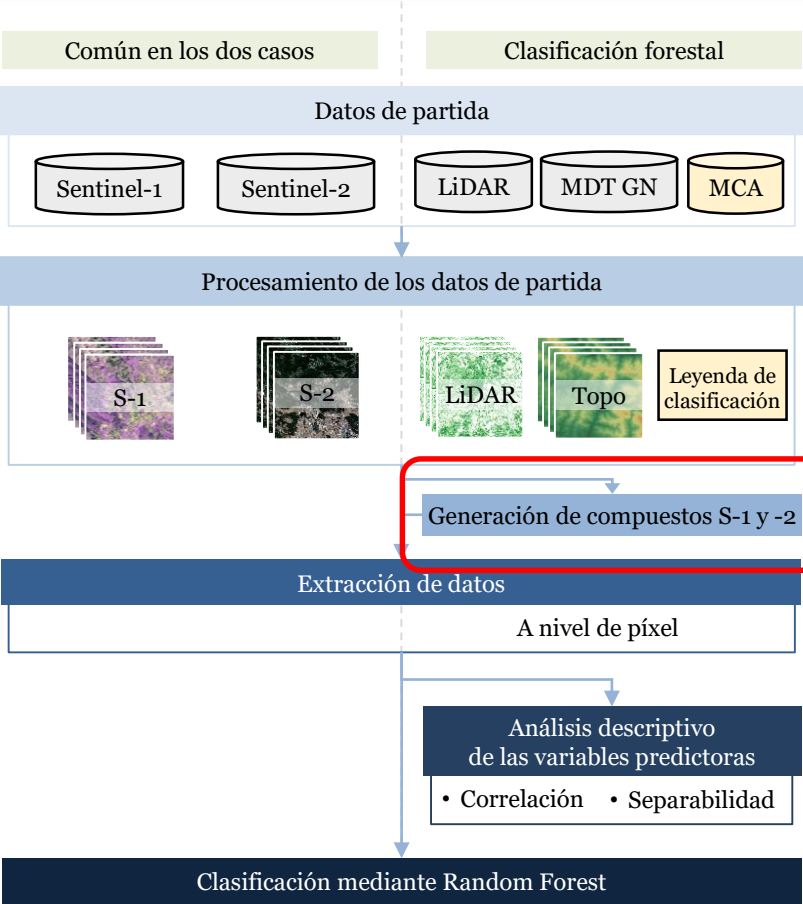
LEYENDA

- Frondosas
- Coníferas
- Mixtas



	nº recintos	sup. (ha)	sup. media
Frondosas	8.789	187.729	21
Coníferas	6.431	89.792	14
Mixto	1.151	12.567	11

Caso de estudio 1: Clasificación de especies forestales. Metodología

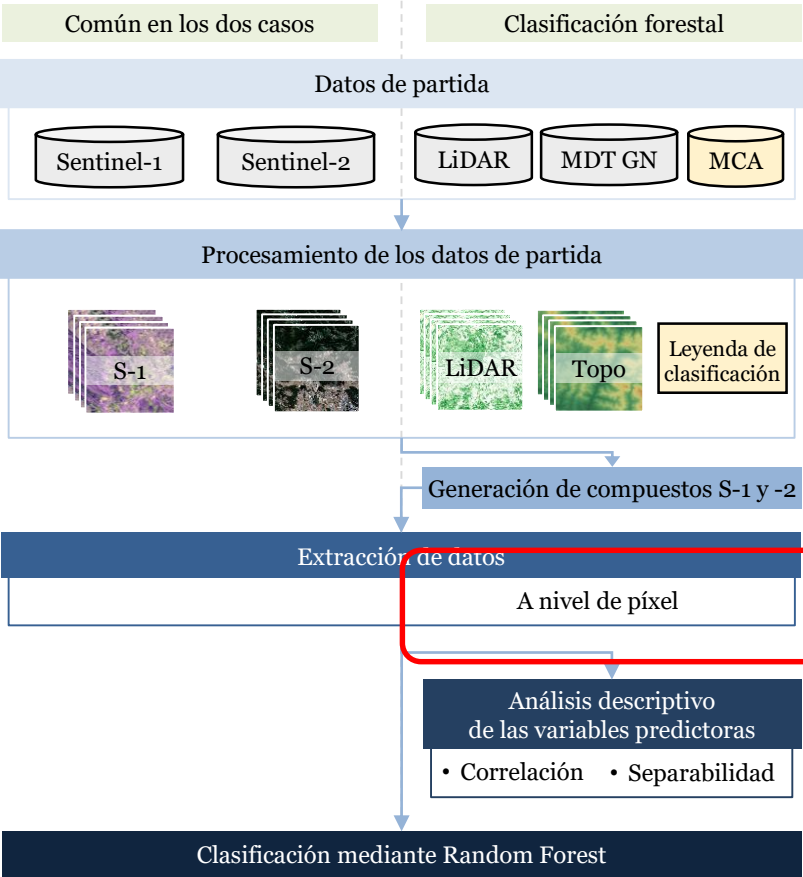


Generación de compuestos mensuales y estacionales de S-1 y S-2

- Falta de datos de píxeles (presencia de nubes)
- Gran volumen de datos de entrada


Ene.		Feb.		Mar.		Abr.		May		Jun.		Jul.		Ag.		Sept.		Oct.		Nov.		Dic.									
5	3	4	-	5	3	3	2	3	4	2	3	3	6	2	4	3	5	2	4	3	3	2	3								
Invierno						Primavera						Verano						Otoño													
14				6				8				9				8				15				7				10			

Caso de estudio 1: Clasificación de especies forestales. Metodología

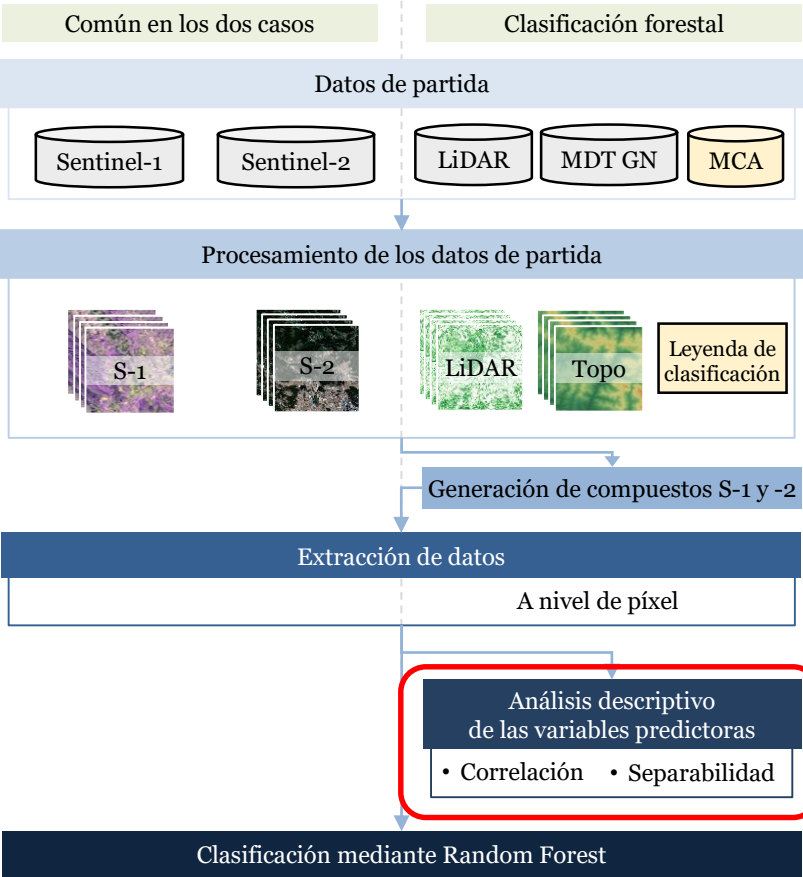


Extracción de datos a nivel de píxel

- 16.371 parcelas \rightarrow malla de $10 \times 10 \rightarrow \sim 25$ M de centroides (~ 6 M de 20×20)
- Muestreo del 5% $\rightarrow \sim 320.900$ muestras




Caso de estudio 1: Clasificación de especies forestales. Metodología



Caso de estudio 1: Clasificación de especies forestales. Metodología


Análisis descriptivo de las variables predictoras

- Correlación entre las variables predictoras

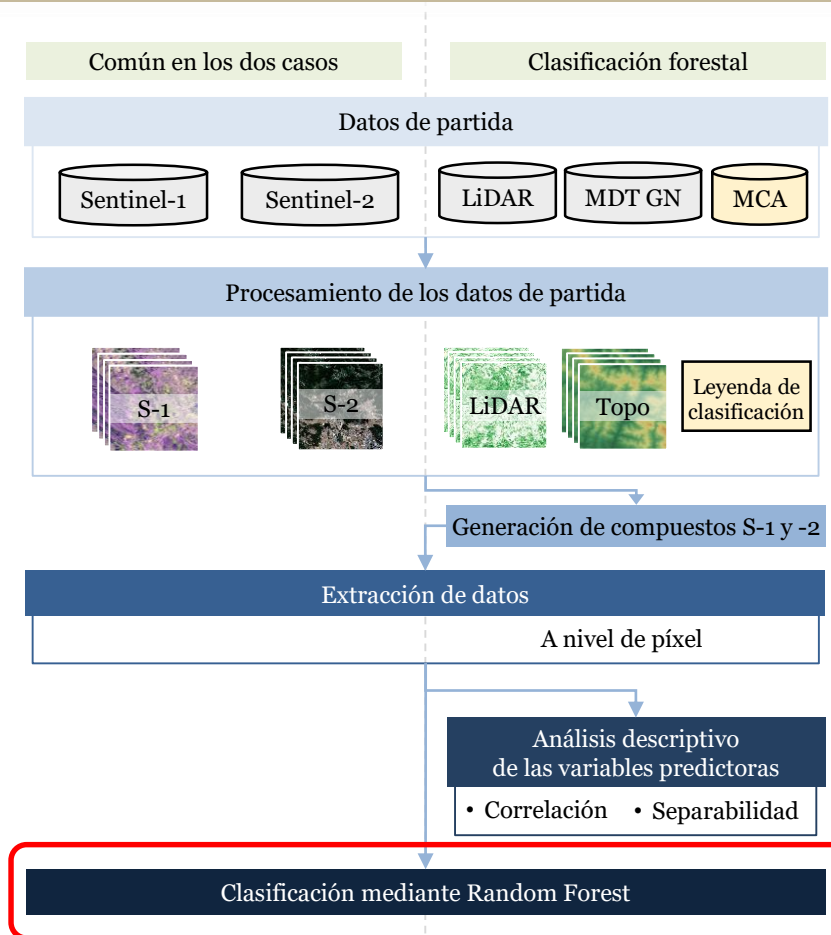


Generación de compuestos mensuales y estacionales

- Separabilidad media entre clases




Caso de estudio 1: Clasificación de especies forestales. Metodología




Clasificación mediante Random Forest

- 1. Muestreo mediante Hold-out: 70/30 (entrenamiento/validación)
- 2. Optimización de hiperparámetros (nivel 2)



- 3. Equilibrado de muestras (nivel 2)




- 4. Selección de variables predictoras (VP)
 - 4.1. Combinación de VP de diferentes sensores
 - 4.2. Reducción del nº de VP: compuestos mensuales vs. estacionales

Caso de estudio 1: Clasificación de especies forestales. Resultados

CLASIFICACIÓN MEDIANTE RANDOM FOREST


Selección de variables predictoras de diferentes sensores



- Fiabilidad: Nivel 1 > Nivel 2 > Nivel 3
- Bandas base: S-1,S-2 > S-2 > S-1 > LiDAR
- Añadir Topo como VP:
 - ✓ Mejoras mayores en niveles más específicos
- Añadir LiDAR y Topo como VP:
 - ✓ Mejora la fiabilidad en todos los casos
 - ✓ Mayor influencia en S-1 que en S-2

CLASIFICACIÓN MEDIANTE RANDOM FOREST

Reducción en el número de variables predictoras mediante compuestos



- Reducción de 207 a 92 bandas
- Compuestos mensuales > estacionales
- Diferencia de fiabilidad entre compuestos:
Nivel 1 < Nivel 2 < Nivel 3


CLASIFICACIÓN MEDIANTE RANDOM FOREST

Clasificación Nivel 1: 3 clases

Matriz de confusión

		Predicciones			
		Frondosas	Coníferas	Mixtas	Total
Verdad terreno	Frondosas	59432	2273	1494	63199
	Coníferas	1785	25948	1242	28975
	Mezcla	1041	1551	1510	4102
	Total	62258	29772	4246	96276
Precisión (%)		95,46	87,16	35,56	
Recall (%)		94,04	89,55	36,81	
Fiabilidad global (%)					90,25

Importancia de variables predictoras (top 15)



Caso de estudio 1: Clasificación de especies forestales. Resultados

CLASIFICACIÓN MEDIANTE RANDOM FOREST


Clasificación Nivel 2: 11 clases

Matriz de confusión

		Predicciones												
		Frondosas				Coníferas				Mixtas				
		1	2	3	4	5	6	7	8	9	10	11	Total	
Verdad terreno	Frondosas	1	31469	718	5	1516	0	10	252	105	663	24	142	34904
		2	1014	16643	12	2543	436	258	486	120	104	396	51	22063
		3	35	22	84	153	0	0	0	3	1	0	0	298
		4	1218	761	11	3601	30	17	70	93	102	24	7	5934
	Coníferas	5	0	186	1	11	6220	236	48	0	0	1	20	6723
		6	18	364	0	22	227	4498	415	58	5	34	45	5686
		7	194	669	0	36	101	610	11669	55	475	468	26	14303
		8	89	93	0	145	188	99	144	1468	14	5	18	2263
	Mezcla	9	201	87	0	22	0	6	296	5	572	14	1	1204
		10	12	329	0	16	6	72	652	4	72	606	2	1771
		11	86	178	0	40	138	150	89	68	12	17	349	1127
Total		34336	20050	113	8105	7346	5956	14121	1979	2020	1589	661	96276	
PA (%)		91,65	83,01	74,34	44,43	84,67	75,52	82,64	74,18	28,32	38,14	52,80		
UA (%)		90,16	75,43	28,19	60,68	92,52	79,11	81,58	64,87	47,51	34,22	30,97		
OA (%)		80,17												

			Frondosas	Coníferas	Mixtas
1	Haya	5	Pino alepo	9	Pino silvestre-Hayedo
2	Quercus	6	Pino laricio	10	Pino silvestre-Robledal
3	Frondosas nobles	7	Pino silvestre	11	Otras mezclas mixtas
4	Otras frondosas	8	Otras coníferas		

Importancia de variables predictoras (top 15)



Caso de estudio 1: Clasificación de especies forestales. Resultados


CLASIFICACIÓN MEDIANTE RANDOM FOREST

Clasificación Nivel 3: 23 clases

Matriz de confusión

Verdad terreno	Predicciones																							Total
	Frondosas											Coníferas								Mixtas				
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	
1	491	1	45	2	1	165	0	0	2	84	0	0	0	5	7	0	9	0	1	0	0	0	0	813
2	0	6999	14	165	1	0	0	43	0	45	0	283	94	0	0	166	2	0	0	0	8	36	25	7881
3	56	47	31471	736	0	478	0	8	19	891	6	2	14	1	20	237	47	22	6	166	656	18	3	34904
4	5	231	411	5422	0	84	0	165	15	284	3	18	57	1	3	187	4	0	1	0	75	227	11	7204
5	0	4	0	3	56	3	0	0	0	4	0	3	1	1	0	0	2	0	0	0	0	0	0	77
6	112	2	273	105	1	1980	0	1	25	366	3	1	5	15	10	1	3	0	1	0	0	0	0	2904
7	0	0	0	1	0	0	26	0	0	58	0	4	0	0	0	0	0	0	0	0	0	0	0	89
8	0	77	0	169	0	7	0	0	1170	0	12	0	26	43	0	1	7	0	0	0	0	17	5	1534
9	20	1	93	85	0	111	0	0	266	157	0	2	0	3	0	1	2	0	0	0	3	0	0	744
10	178	616	1273	774	4	915	16	120	77	2536	6	70	40	22	14	98	24	1	5	0	107	43	18	6957
11	0	0	25	8	0	1	0	2	0	8	46	0	1	0	0	0	0	0	0	0	1	0	0	92
12	0	154	0	16	0	0	0	29	0	15	0	6206	219	1	0	52	0	0	4	0	0	1	26	6723
13	1	176	19	86	0	19	0	88	0	23	0	248	4466	22	2	432	10	2	2	0	7	31	52	5686
14	4	0	3	1	0	27	0	0	0	26	0	0	17	207	5	1	6	0	0	0	0	0	0	297
15	8	0	46	15	0	25	0	0	1	29	0	0	1	1	506	7	12	2	1	1	4	0	0	659
16	0	321	181	346	0	2	0	16	0	44	0	125	626	5	5	11594	36	2	2	8	488	480	22	14303
17	1	3	21	8	0	7	0	0	1	34	0	0	9	4	4	62	273	2	0	14	10	2	0	455
18	1	2	5	2	0	2	0	0	10	0	30	7	6	0	1	8	273	3	0	0	0	0	3	353
19	0	17	12	4	0	3	0	4	0	13	0	144	69	6	7	54	29	2	128	0	4	2	1	490
20	0	0	57	0	0	0	0	0	0	0	0	0	0	0	0	9	25	0	0	158	2	1	0	252
21	0	9	181	84	0	1	0	2	0	19	0	0	6	0	1	292	3	0	0	3	592	11	0	1204
22	0	46	13	286	0	4	0	32	1	14	0	8	65	0	2	640	1	0	1	0	73	581	4	1771
23	4	109	22	46	0	13	0	14	0	34	0	134	137	10	6	72	15	16	1	0	12	14	216	876
Total	881	8815	34165	8364	63	3847	42	1694	407	4706	64	7304	5877	310	593	13913	511	322	156	350	2042	1464	386	96276
PA	55,73	79,40	92,11	64,83	88,89	51,47	61,90	69,07	65,36	53,89	71,88	84,97	75,99	66,77	85,33	83,33	53,42	84,78	82,05	45,14	28,99	39,69	55,96	
UA	60,39	88,81	90,16	75,26	72,73	68,18	29,21	76,27	35,75	36,45	50,00	92,31	78,54	69,70	76,78	81,06	60,00	77,34	25,65	62,70	49,17	32,81	24,69	
OA																								78,57

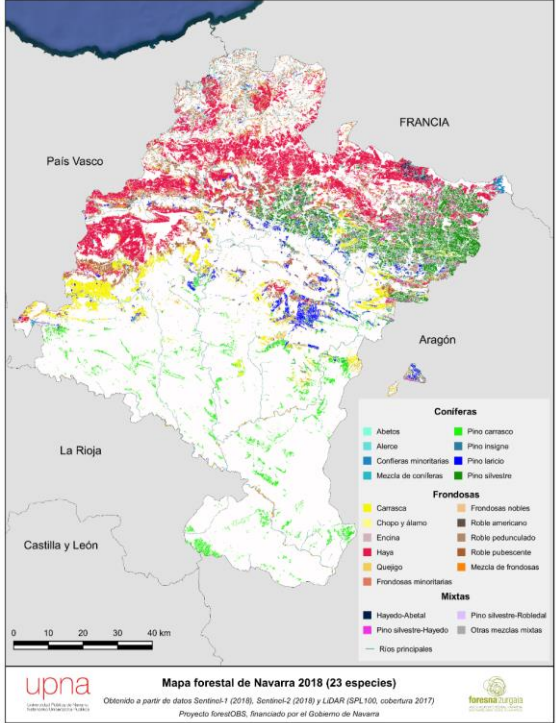
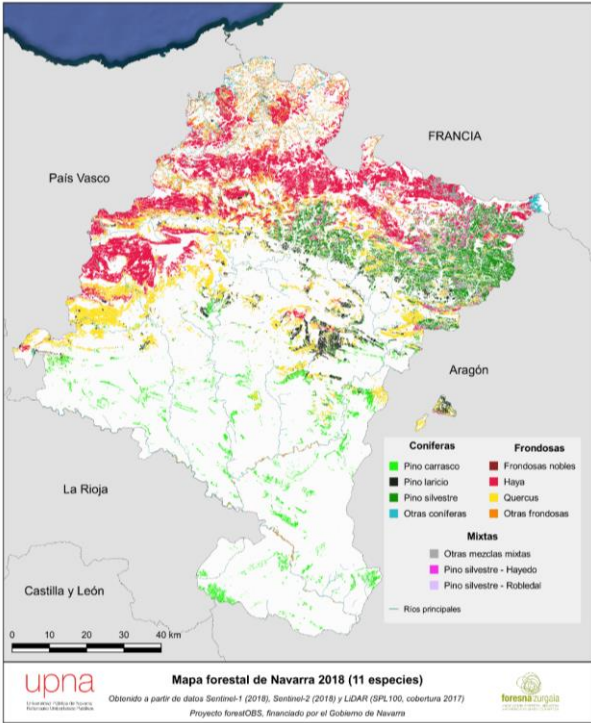
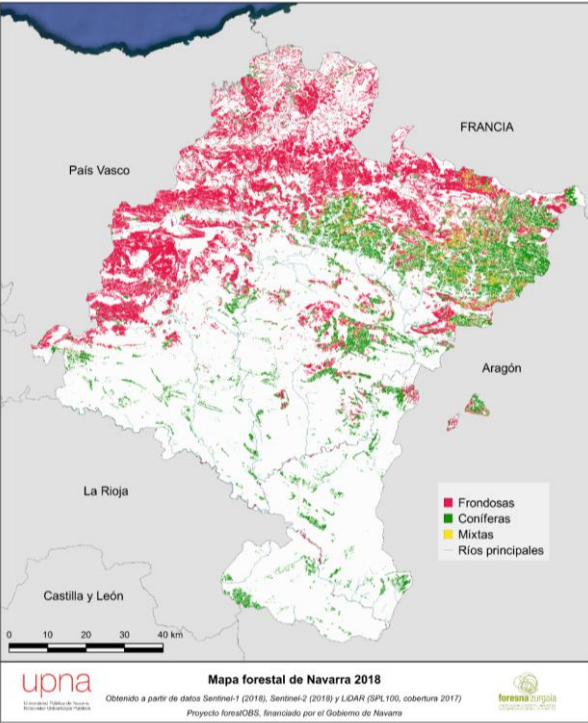
Importancia de variables predictoras (top 15)



Fronosas					Coníferas					Mixtas				
1	Roble americano	7	Chopo y álamo		12	Pino alepo	17	Abetos		20	Hayedo-Abetal			
2	Carrasca	8	Quejigo		13	Pino laricio	18	Coníferas minoritarias		21	Pino silvestre-Hayedo			
3	Haya	9	Fronosas minoritarias		14	Pino insignie	19	Mezcla de coníferas		22	Pino silvestre-Robledal			
4	Roble pubescente	10	Mezcla de frondosas							23	Otras mezclas mixtas			
5	Encina	11	Fronosas nobles		16	Pino silvestre								
6	Roble pedunculado													


Caso de estudio 1: Clasificación de especies forestales. Resultados

MAPAS OBTENIDOS



Política Agraria Común (PAC)

- La Comisión Europea aprobó una modificación de la PAC que, entre otros aspectos, recomienda el uso de datos derivados de imágenes Sentinel o similares
- Con esto se pretende verificar el cultivo declarado para una parcela específica



Clasificación por recinto

- La metodología OBIA (Object-Based Image Analysis) que analiza los datos agregándolos en objetos significativos basados en sus atributos
- Lo cual es posible a través del Sistema de Identificación de Parcelas de Cultivo (SIGPAC), que permite utilizar información de parcelas agrícolas reales.



Declaraciones e Inspecciones

- Los datos de campo fueron obtenidos de la base de datos del Departamento de Agricultura del Gobierno de Navarra, que contienen los polígonos del las declaraciones (255120) e inspecciones (22446) PAC del año 2017.

Leyenda de Cultivos

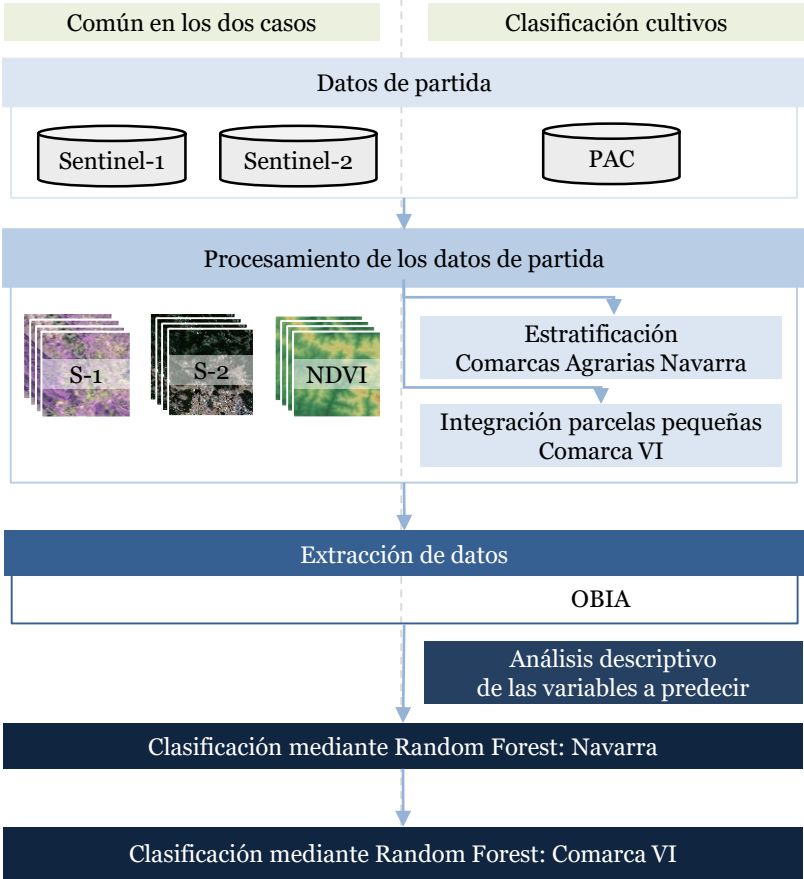
- Entre 147-150 cultivos/usos del suelo diferente
- Se propone agrupar los distintos cultivos en base a criterios de:
 - Similitud fenológica
 - Características morfológicas

Parcelas pequeñas e irregulares

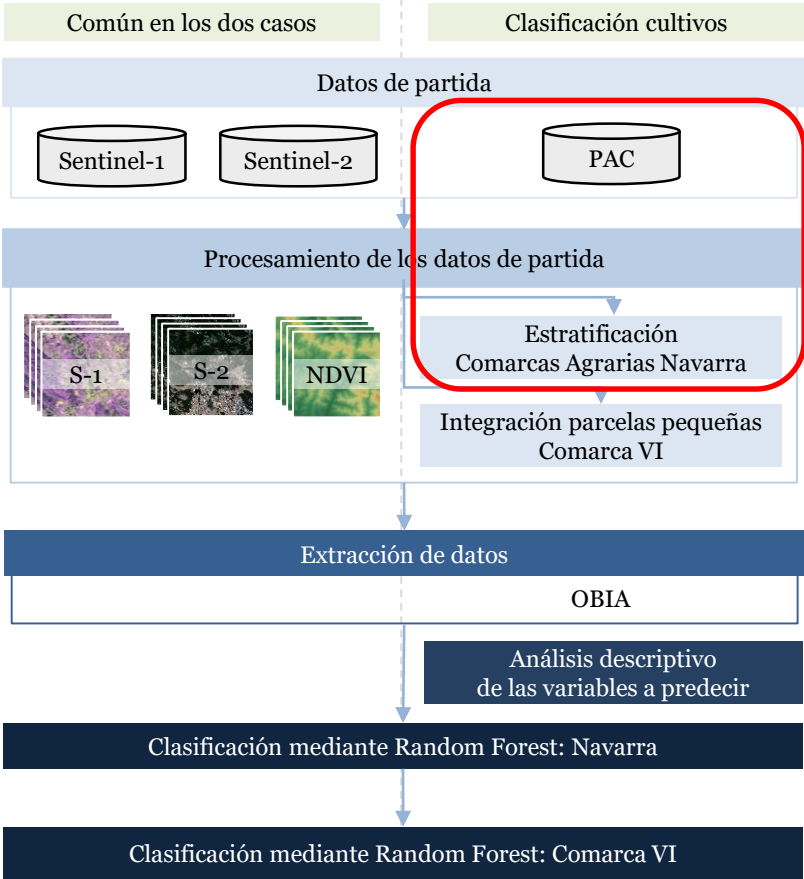
- Sistemas agrícolas con una alta presencia de parcelas pequeñas presentan bajas fiabilidades en modelos de clasificación

CULTIVO	DECLARACIONES				INSPECCIONES			
	Nº de parcelas	Área (ha)	Área (%)	Área promedio (ha)	Nº de parcelas	Área (ha)	Área (%)	Área promedio (ha)
ALFALFA	3917	3601,2	1,34	0,9	286	316,1	1,44	1,1
ALMENDROS	3549	1606,1	0,6	0,5	191	133,9	0,61	0,7
ARROZ	813	1438,2	0,53	1,8	120	180,2	0,82	1,5
AVENA	6446	9053,8	3,37	1,4	458	612,2	2,79	1,3
BARBECHO	27553	23840,2	8,87	0,9	2669	1952,7	8,9	0,7
CEBADA	38005	50194,9	18,67	1,3	3825	5031,1	22,94	1,3
COLZA	1991	2952,9	1,1	1,5	311	367,5	1,68	1,2
ESPÁRRAGOS	1153	828,4	0,31	0,7	93	70,3	0,32	0,8
FRUTALES	3959	1469,8	0,55	0,4	218	64,0	0,29	0,3
GIRASOL	1064	2214,2	0,82	2,1	158	328,5	1,5	2,1
GUISANTE	1964	3266,7	1,22	1,7	320	525,2	2,39	1,6
HABAS	1421	1723,8	0,64	1,2	197	291,5	1,33	1,5
MAÍZ	6587	10483,1	3,9	1,6	592	905,6	4,13	1,5
MEZCLAS CON CEREAL	675	715,0	0,27	1,1	86	128,1	0,58	1,5
OLIVAR	11192	3369,5	1,25	0,3	920	210,2	0,96	0,2
PASTOS ARBOLADOS	2440	4397,6	1,64	1,8	317	716,9	3,27	2,3
PASTOS ARBUSTIVOS	35844	38154,4	14,19	1,1	4669	2713,4	12,37	0,6
PASTOS HERBÁCEOS	48978	37262,7	13,86	0,8	2708	2266,1	10,33	0,8
SUPERFICIES FORESTALES	8208	13168,3	4,9	1,6	34	26,8	0,12	0,8
TOMATE	680	1281,6	0,48	1,9	43	98,6	0,45	2,3
TRIGO	34117	45075,5	16,77	1,3	3013	3803,9	17,34	1,3
VEZA	2045	2102,6	0,78	1,0	364	391,8	1,79	1,1
VIÑA	12519	10647,2	3,96	0,9	854	800,2	3,65	0,9
TOTAL	255120	268847,7	100	27,5	22446	21934,8	100	27,4

Caso de estudio 2: Clasificación de cultivos. Metodología



Caso de estudio 2: Clasificación de cultivos. Metodología



Caso de estudio 2: Clasificación de cultivos. Metodología

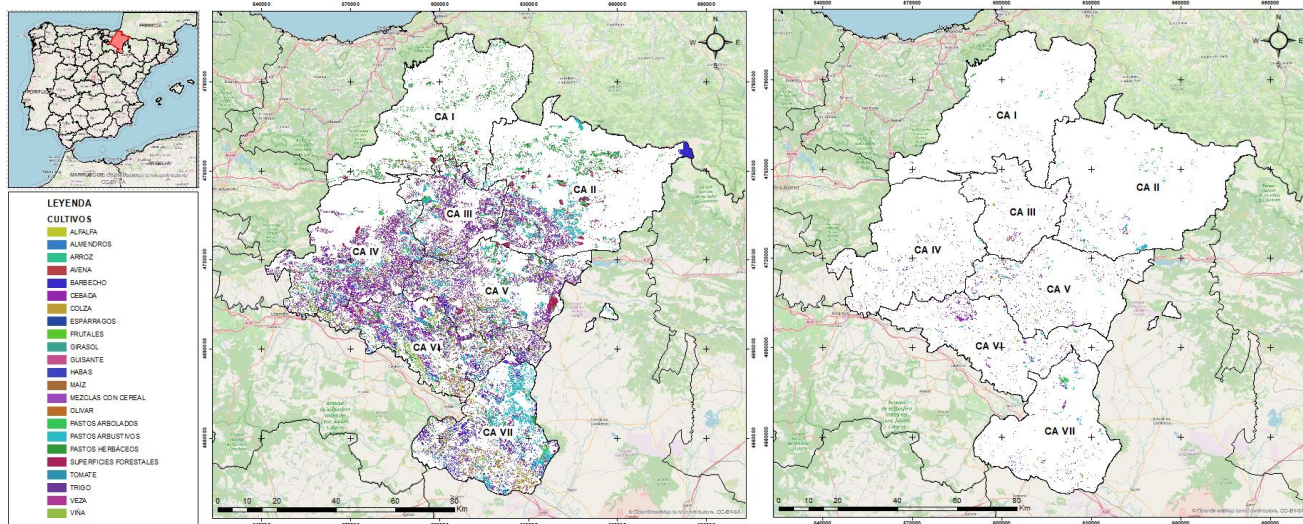
Procesamiento de los datos de partida

Estratificación Comarcas Agrarias Navarra

Declaraciones PAC Navarra

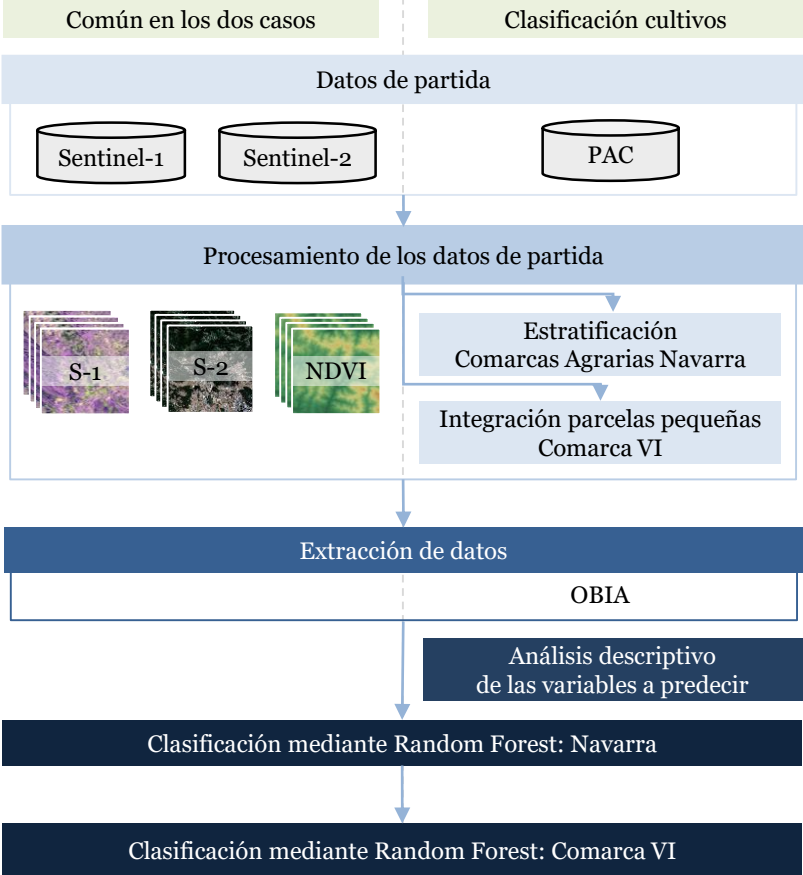
QGIS

1. Generar fichero de declaraciones e inspecciones por comarca agraria
 - Condiciones climatológicas diferentes
 - Ciclos fenológicos y de desarrollo distinto para los mismos cultivos
2. Aplicar buffer interior de 5 m a todas las parcelas

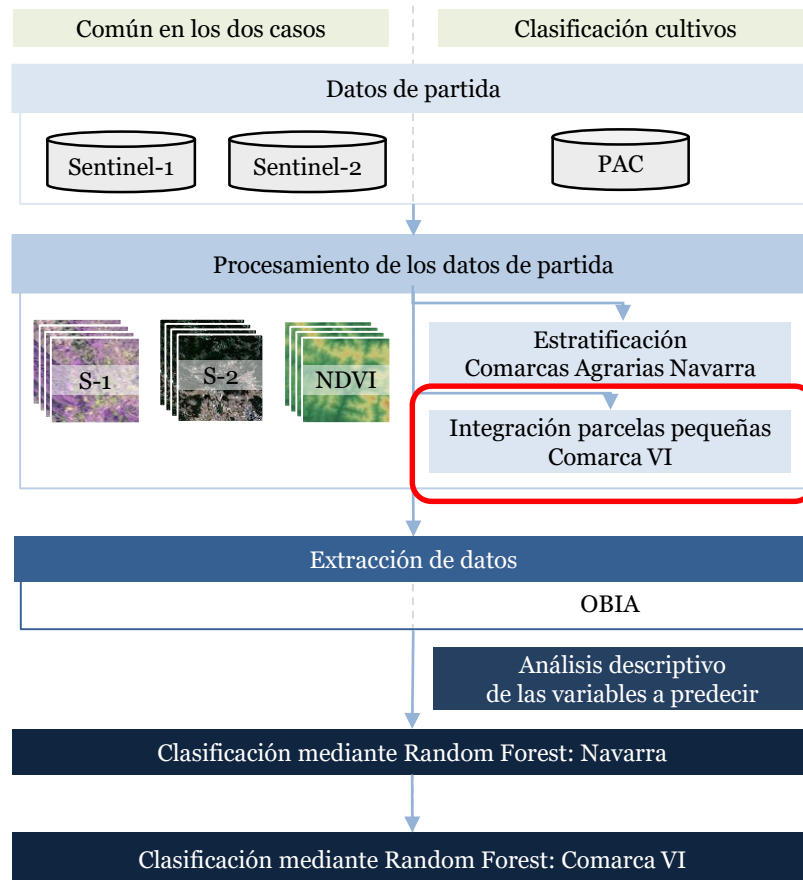


Clasificación de cultivos y cubiertas forestales de Navarra con Sentinel-1, Sentinel-2 y LiDAR

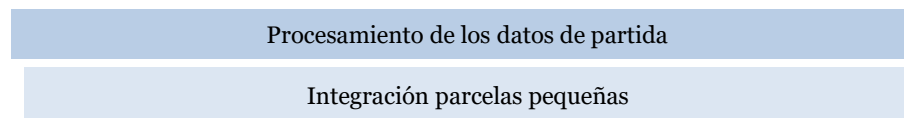
Caso de estudio 2: Clasificación de cultivos. Metodología



Caso de estudio 2: Clasificación de cultivos. Metodología



Caso de estudio 2: Clasificación de cultivos. Metodología





Declaraciones PAC

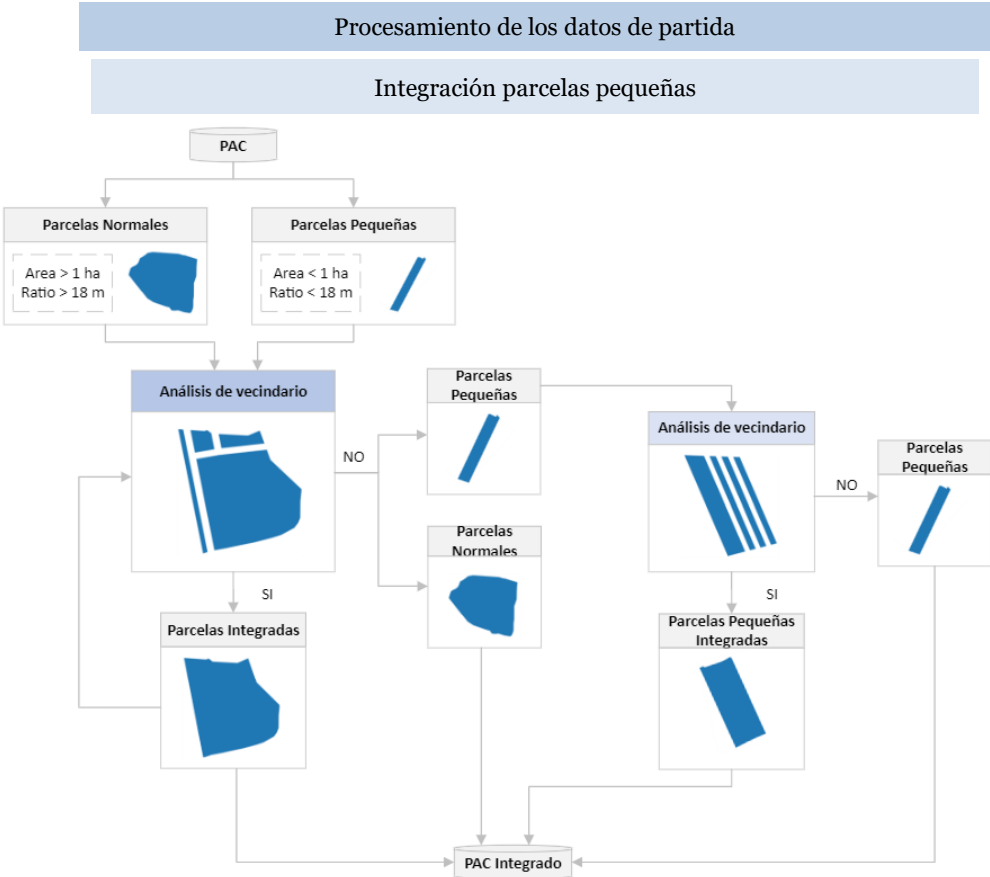
Python

1. Distribución de área (ha) y ratio (área/perímetro) de las parcelas

		DECLARACIONES	INSPECCIONES
Nº Total Parcelas		40023	4033
Area (ha)	Mean	1,3	1,2
	Std	3,4	3,1
Ratio (m)	Mean	16	15,9
	Std	13,8	13,9

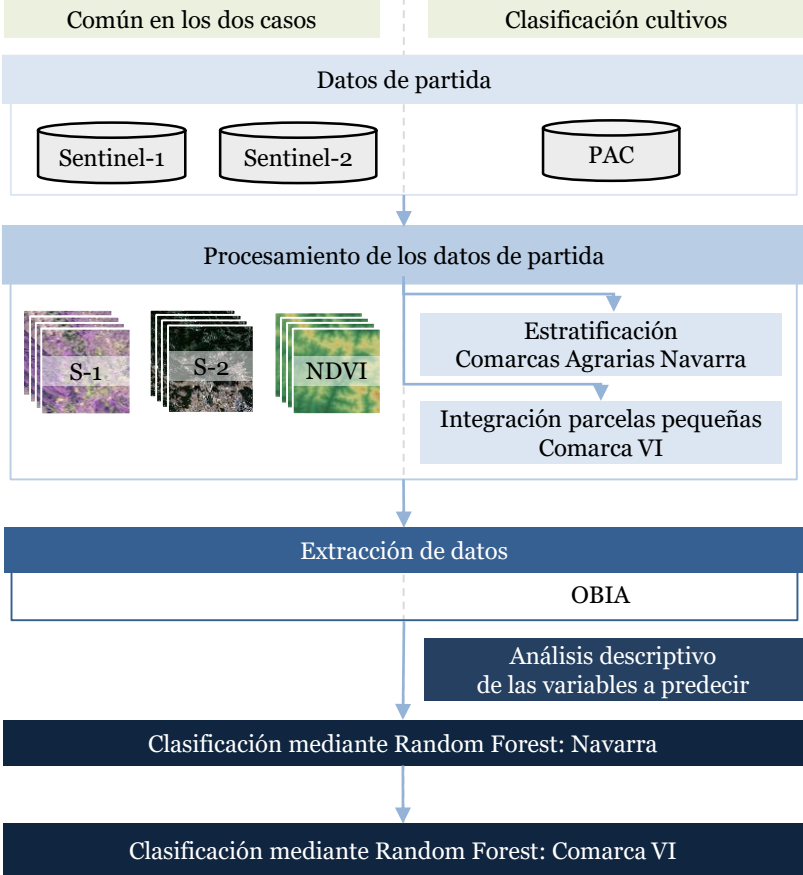
2. Definición del umbral de ratio (área/perímetro)



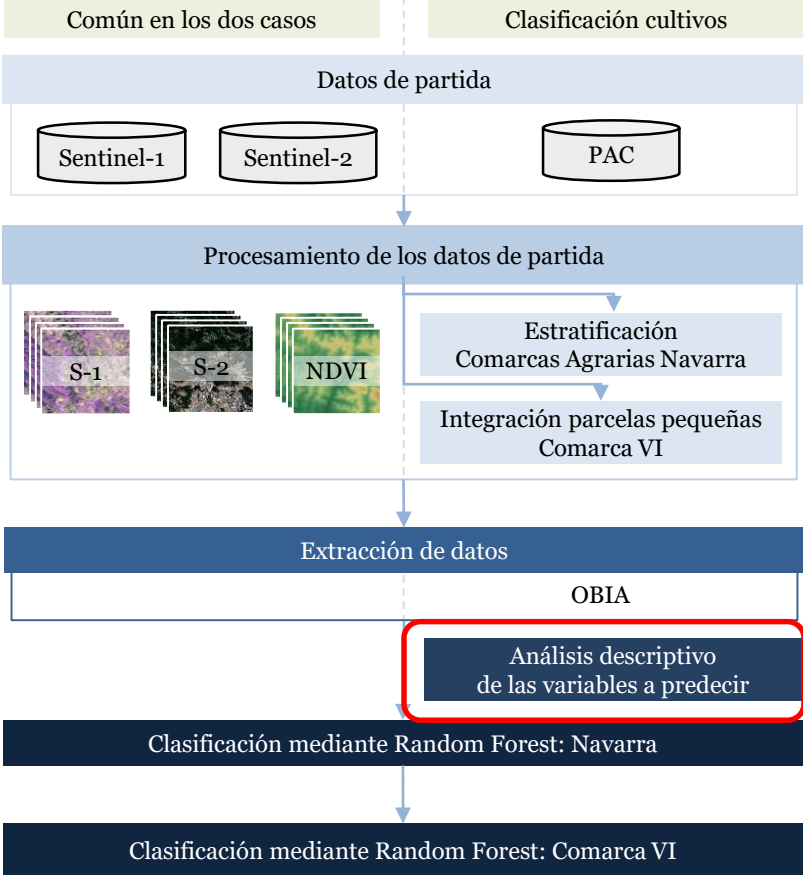


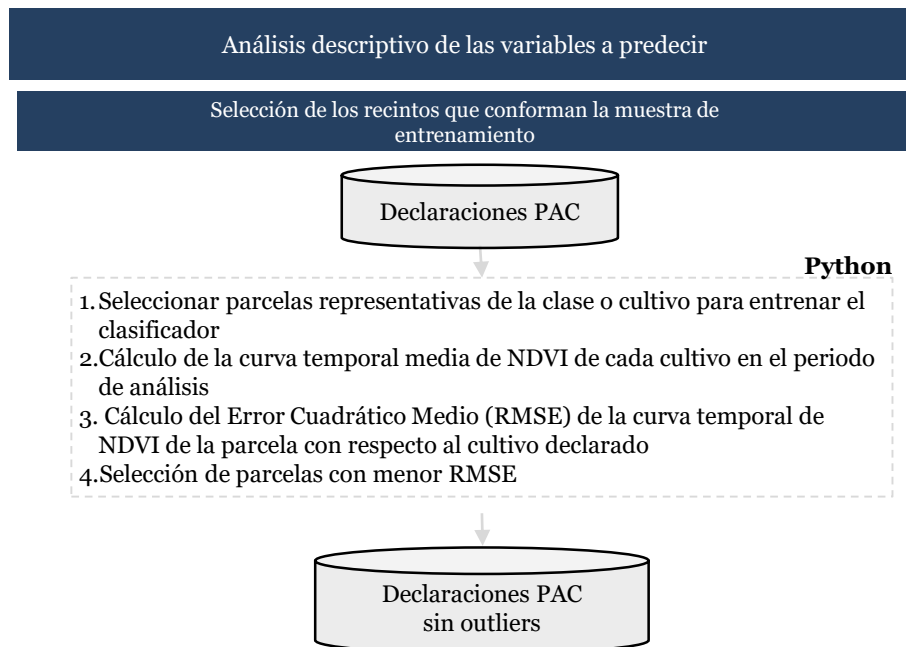
Python

Caso de estudio 2: Clasificación de cultivos. Metodología

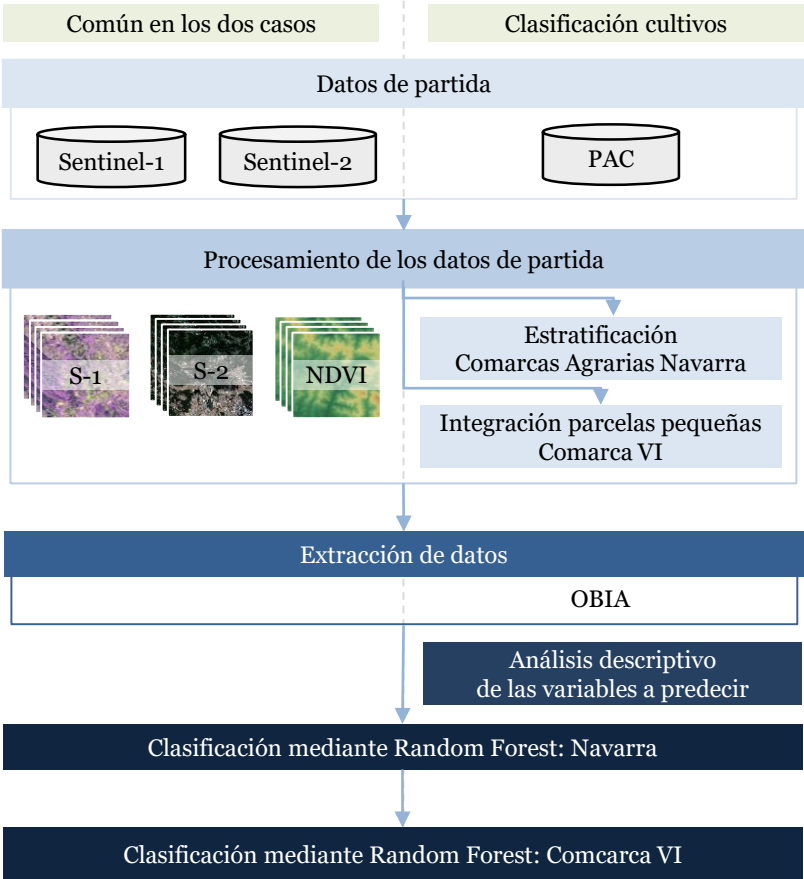


Caso de estudio 2: Clasificación de cultivos. Metodología





Caso de estudio 2: Clasificación de cultivos. Metodología




Caso de estudio 2: Clasificación de cultivos. Metodología



Clasificación mediante Random Forest

- 1. Optimización de modelo para cada comarca agraria mediante validación cruzada (5 y 10) con el fichero de declaraciones: 80/20 (entrenamiento/validación)
- 2. Balanceo de muestras


S2 (VC=5) S2 (VC=10) S1 y S2 (VC=5) S1 y S2 (VC=10)



- 4. Evaluación de variables predictoras (VP)
- 5. Evaluación de la fiabilidad de los modelos con el fichero de inspecciones

CLASIFICACIÓN MEDIANTE RANDOM FOREST: NAVARRA

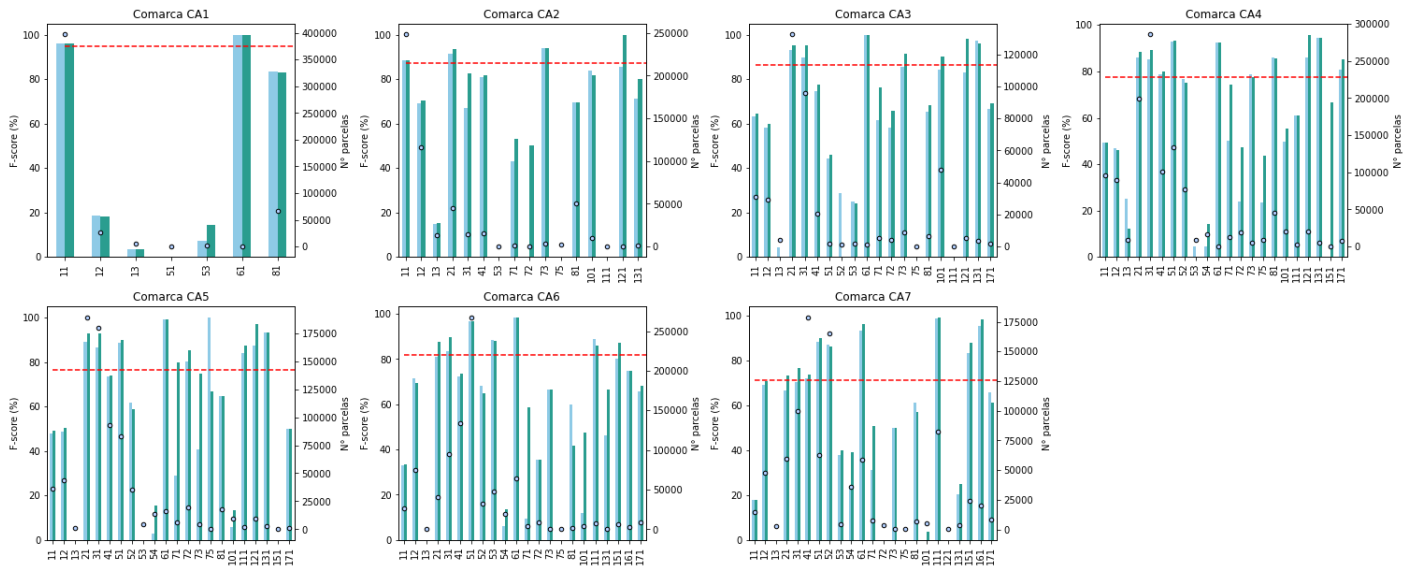
Resultados Comarcas agrarias Navarra



CLASIFICACIÓN MEDIANTE RANDOM FOREST: NAVARRA

Resultados Comarcas agrarias Navarra

--- Fiabilidad Global S1 y S2 F-score solo S2 F-score S1 y S2



ID Cultivo	Cultivo	ID Cultivo	Cultivo	ID Cultivo	Cultivo	ID Cultivo	Cultivo
111	Alfalfa	31	Cebada	61	Maíz	11	P. Herbáceos
54	Almendros	171	Espárragos	75	Mezclas cereal	81	S. Forestales
161	Arroz	53	Frutales	52	Olivar	151	Tomate
101	Avena	131	Girasol	13	P. Arbolados	21	Trigo
41	Barbecho	71	Guisante	12	P. Arbustivos	72	Veza
						51	Viña



CLASIFICACIÓN MEDIANTE RANDOM FOREST

Evaluación de variables predictoras



CLASIFICACIÓN MEDIANTE RANDOM FOREST

Resultados Comarca Agraria VI



Caso de estudio 1: Clasificación de especies forestales

- Las bandas de los meses de abril (B11), de verano (Red Edge, NIR, NDVI, NDII), de diciembre (NBR) y el MDT fueron las variables predictoras más importantes en cuanto a separabilidad e importancia de variables.
- Reducir el número de variables predictoras (de mensuales a estacionales) supuso una reducción de la fiabilidad de los modelos.
- El MDT y las métricas LiDAR cobraron mayor importancia como variables predictoras a medida que las agrupaciones de especies a clasificar fueron más homogéneas (Nivel 3).

Caso de estudio 2: Clasificación de cultivos

- Añadir datos de Sentinel-1 como variables predictoras genera mejores resultados en todos los modelos, especialmente en las comarcas al norte de Navarra donde la presencia de nubes es alta.
- El índice NDVI fue una variable predictora importante en el entrenamiento de los modelos de todas las comarcas agrarias.
- Se puede mejorar la clasificación de parcelas pequeñas mediante su integración con parcelas vecinas en las que se ha declarado el mismo cultivo.

Conclusiones generales

- Es posible generar mapas temáticos de especies forestales y de cultivos con una alta fiabilidad (~80%) a partir de imágenes del programa Copernicus distribuidas libremente.
- El procesado e implementación de estas técnicas se puede abordar mediante herramientas libres.
- Combinar datos procedentes de diferentes sensores mejora la clasificación.

Agradecimientos:



Proyecto **ReSAg** (Remote sensing for a Sustainable Agriculture)
Programa Estatal de I+D+i orientada a los Retos de la Sociedad 2019
PID2019-107386RB-I00



Proyecto **forestOBS** (Herramientas de gestión forestal basadas en tecnologías de observación de la tierra)
Ayudas para realizar proyectos de I+D 2021. Modalidad de transferencia

Conclusiones generales

- Es posible generar mapas temáticos de especies forestales y de cultivos con una alta fiabilidad (~80%) a partir de imágenes del programa Copernicus distribuidas libremente.
- El procesado e implementación de estas técnicas se puede abordar mediante herramientas libres.
- Combinar datos procedentes de diferentes sensores mejora la clasificación.

gràcies per la seva atenció!!

Agradecimientos:



Proyecto **ReSAg** (Remote sensing for a Sustainable Agriculture)
Programa Estatal de I+D+i orientada a los Retos de la Sociedad 2019
PID2019-107386RB-I00



Proyecto **forestOBS** (Herramientas de gestión forestal basadas en tecnologías de observación de la tierra)
Ayudas para realizar proyectos de I+D 2021. Modalidad de transferencia